

Kódování s proměnnou délkou slov

Zdeněk VAŠÍČEK

Fakulta informačních technologií, Vysoké učení technické v Brně

Brno, Czech Republic

vasicek@fit.vutbr.cz



Obsah

■ Kódování

- Jednoznačně dekódovatelné kódování, prefixové kódy, optimální kódování

■ Stručný úvod do teorie informace

- Entropie, redundance, Kraft–McMillanova nerovnost, optimální prefixové kódování
- Vztah entropie a kódování

■ Kódování celých čísel

- Univerzální kódování pro reprezentaci celých čísel.
- Unární kódování; Eliasovo gama, delta a omega kódování; Start-Step-Stop kódování; Golomb-Riceovo kódování, VLQ
- Vztah Golombova kódování a RLE

Kódování

- Předpokládejme, že máme vstupní tok, který se skládá ze symbolů z abecedy $\Sigma = \{s_1, \dots, s_n\}$, kterou budeme nazývat *zdrojová abeceda*.
- Mějme danu abecedu Γ tvořenou $|\Gamma|$ symboly, kterou budeme nazývat *abeceda kódových slov*.
- DEFINICE: **Kódování** nebo kód je formálně definováno jako **injektivní zobrazení** $f: \Sigma \rightarrow \Gamma^*$, kde Γ^* je množina konečných řetězců symbolů z Γ , tj. každému symbolu z abecedy Σ je přiřazeno nanejvýš jedno tzv. *kódové slovo* nad abecedou Γ .
 - Trojice (Σ, Γ, f) , kde platí podmínka jednoznačnosti $\forall_{a_1, a_2 \in \Sigma: a_1 \neq a_2 \Rightarrow f(a_1) \neq f(a_2)}$.
- Poznámky:
 - Pokud $\Gamma = \{0,1\}$, pak hovoříme o binárním kódování.
 - Abeceda Σ může být libovolná, potenciálně nekonečná, množina (viz např. množina přirozených čísel)



Rozšířené kódování

- Zprávou rozumíme každý konečný řetězec zdrojových slov $s = s_{i_1} \cdots s_{i_k}$, kde $s_j \in \Sigma$.
- DEFINICE: Pokud f je kódování, pak **rozšíření kódování** znaků na kódování zpráv (tj. f na Σ^*) je definováno obvyklým způsobem pomocí zřetězení, tj.

$$f^+(s) = f(s_{i_1} s_{i_2} \cdots s_{i_k}) = f(s_{i_1}) \cdots f(s_{i_k}).$$

- Pro další výklad budeme uvažovat vždy $f^+(s)$, je-li vstupem f řetězec tvořený znaky Σ
- Příklad:
 - Uvažujme $\Sigma = \{A,B,C\}$, $\Gamma = \{0,1\}$ a zobrazení $f: \Sigma \rightarrow \Gamma^*$ definované následovně:
 $A \rightarrow 01$, $B \rightarrow 1$, $C \rightarrow \emptyset$
 - $f(\text{BABA}) = 101101$

Kódování – příklad

- Dopředný proces převodu zprávy nad zdrojovou abecedou Σ na zprávu nad kódovou abecedou Γ se nazývá kódování, opačný proces pak dekódování.
- Morseův kód je případem kódu s proměnnou délkou slov
 - Zkonstruuje binární kód, tj. $\Gamma = \{0,1\}$.
Vstupní abeceda je tvořena alfanumerickými znaky
 $\Sigma = \{A,B,C,D,E,\dots\}$
 - Zobrazení $f: \Sigma \rightarrow \Gamma^*$ je definováno následovně:
 $A \rightarrow 01$, $B \rightarrow 1000$, $C \rightarrow 1010$, $D \rightarrow 100$, ...
 - Pokud však aplikujeme kódování na řetězce,
narazíme na problém s nejednoznačností:
 $CAT \rightarrow 1010011$, $KIM \rightarrow 1010011$, $TETEETT \rightarrow 1010011$, ...

A ● ■■■
 B ■■■ ● ● ●
 C ■■■ ● ■■■ ●
 D ■■■ ● ●
 E ●
 F ● ● ■■■ ●
 G ■■■ ■■■ ●
 H ● ● ● ●
 I ● ●
 J ● ■■■ ■■■ ■■■
 K ■■■ ● ■■■
 L ● ■■■ ● ●
 M ■■■ ■■■
 N ■■■ ●
 O ■■■ ■■■ ■■■
 P ● ■■■ ■■■ ●
 Q ■■■ ■■■ ● ■■■
 R ● ■■■ ●
 S ● ● ●
 T ■■■

U ● ● ■■■
 V ● ● ● ■■■
 W ● ■■■ ■■■
 X ■■■ ● ● ■■■
 Y ■■■ ● ■■■ ■■■
 Z ■■■ ■■■ ● ●

1 ● ■■■ ■■■ ■■■ ■■■
 2 ● ● ■■■ ■■■ ■■■
 3 ● ● ● ■■■ ■■■
 4 ● ● ● ● ■■■
 5 ● ● ● ● ●
 6 ■■■ ● ● ● ●
 7 ■■■ ■■■ ● ● ●
 8 ■■■ ■■■ ■■■ ● ●
 9 ■■■ ■■■ ■■■ ■■■ ●
 0 ■■■ ■■■ ■■■ ■■■ ■■■

Jednoznačně dekódovatelné kódování

- DEFINICE: Kódování f je **jednoznačně dekódovatelné**, jestliže každý konečný řetězec z Γ^* je obraz nejvýše jedné zprávy, tj. $\forall_{s_1, s_2 \in \Sigma^*}: f(s_1) = f(s_2) \Rightarrow s_1 = s_2$.
 - Teoreticky mohou existovat i slova, která nemají v daném kódu vzory.
- **Není jednoduché rozhodnout, zda je daný kód jednoznačný**
 - je nutné typicky nalézt protipříklad (viz Sardinas-Patterson algorithm).
- **Podmínka jednoznačné dekódovatelnosti nezaručuje, že proces dekódování je jednoduchý.**
 - např. můžeme mít kódování, které je jednoznačné pouze při čtení řetězce pozpátku nebo pokud budeme počítat počet výskytů určitých symbolů
- **Mezi základní jednoznačně dekódovatelné kódování patří:**
 - kódování s pevnou délkou kódových slov, kdy všechna kódová slova mají stejný počet symbolů, (např. běžné n-bitové binární kódování) a
 - mnohem obecnější třída prefixových kódů.

Prefixové kódování (prefix-free, instantaneous) a dekódovatelné kódy

- DEFINICE: Kódování f se nazývá bezprostředně dekódovatelné nebo **prefixové**, jestliže $\forall_{s_1, s_2 \in \Sigma^* : s_1 \neq s_2 \Rightarrow \nexists_{z \in \Gamma^* : f(s_1)z = f(s_2)}$, tj. neexistují různé s_i a s_j takové, že $f(s_i)$ je prefix $f(s_j)$.
 - Prefixové kódování mají velký význam neboť se jedná o jediné kódy, které lze dekódovat symbol po symbolu ihned po přečtení poslední značky kódového slova symbolu.
- Každé prefixové kódování je jednoznačně dekódovatelné .
 - Příklad: mějme $\Gamma = \{0,1\}$ a čtyři symboly w_1, w_2, w_3, w_4 . Kódování $f(w_1) = 0, f(w_2) = 10, f(w_3) = 110, f(w_4) = 1110$ je prefixové a zprávu 01101001010010 lze dekódovat jako sekvenci $w_1 w_3 w_2 w_1 w_2 w_2 w_1 w_2$ bez nutnosti číst bit následujícího slova. Nula signalizuje konec symbolu.
- Ne každé jednoznačně dekódovatelné kódování je prefixové.
 - Příklad: mějme $\Gamma = \{0,1\}$ a tři symboly w_1, w_2, w_3 . Mějme kódování $f(w_1) = 00, f(w_2) = 10, f(w_3) = 100$. Přestože uvedený kód není prefixový, je jednoznačně dekódovatelný.

Průměrná délka kódování

- Pro kódová slova, tj. řetězce $f(s_i)$, můžeme stanovit přirozená čísla $l_i = |f(s_i)|$, která odpovídají délce kódů v kódování f a definovat tzv. průměrnou délku kódování.
- DEFINICE: Necht' $P(s_i)$ odpovídá pravděpodobnosti výskytu symbolu $s_i \in \Sigma$ ve vstupním toku a $D = |\Sigma|$, pak **průměrná délka kódování** f je definovaná jako

$$\langle f \rangle = \sum_{i=1}^D P(s_i) |f(s_i)| = \sum_{i=1}^D P(s_i) l_i$$

- Příklad:
 - Mějme dán zdroj informace, který vysílá symboly $\Sigma = \{a, b, c, d\}$ s pravděpodobností $p = \{0.9, 0.05, 0.025, 0.025\}$. Které kódování je výhodnější použít, máme-li dány dvě kódování: $f: a \rightarrow 0, b \rightarrow 111, c \rightarrow 110, d \rightarrow 101$ a $g: a \rightarrow 00, b \rightarrow 01, c \rightarrow 10, d \rightarrow 11$?

Optimální kódování

- Uvažujme abecedu Γ a funkci $cost: \Gamma \rightarrow \mathbb{R}$ přiřazující každému symbolu abecedy cenu, kterou lze interpretovat např. jako dobu potřebnou k odeslání symbolu určitým komunikačním kanálem.
 - V případě Morseova kódu máme dva případy ceny (1 – tečka, 2 – čárka), neboť odeslat čárku trvá dvakrát delší dobu.

- Cena slova nad abecedou Γ je dána součtem cen jednotlivých symbolů, tj.
 $cost(a_1 \dots a_n) = cost(a_1) + cost(a_2) + \dots + cost(a_n)$.

- DEFINICE: *Průměrná cena kódování* $f: \Sigma \rightarrow \Gamma^*$ s pravděpodobnostmi výskytu $P(s_i)$ jednotlivých symbolů s_i vstupní abecedy Σ je rovna

$$W(f) = \sum_{i=1}^D P(s_i) cost(f(s_i))$$

- V případě uniformní ceny symbolu C platí $W(f) = C\langle f \rangle$
- DEFINICE: Máme-li dány pravděpodobnosti $P(s_i)$ a funkci $cost$, pak f je **optimální kódování** právě tehdy, když $W(f)$ je minimální.


Další vlastnosti kódování

- DEFINICE: Kódování je **afixové**, pokud žádné kódové slovo není příponou (suffixem) jiného slova. Afixový kód je jednoznačně dekódovatelný symbol po symbolu při čtení zprava doleva.
 - Příklad: mějme $\Gamma = \{0,1\}$, dvě kódová slova w_1, w_2 a kódování $f(w_1) = 0, f(w_2) = 01$. Toto kódování není prefixové, ale lze snadno ověřit, že je jednoznačně dekódovatelné, pokud budeme postupovat zpět z konce zprávy.
- DEFINICE: Kódování je **blokové**, pokud všechna kódová slova mají stejnou délku. Blokový kód je jednoznačně dekódovatelný při čtení libovolným směrem.
- DEFINICE: Necht' S, C jsou dvě uspořádané abecedy. Říkáme, že kódování f je **uspořádané** pokud platí, že $\forall_{a_1, a_2 \in \Sigma: a_1 < a_2 \Rightarrow f(a_1) < f(a_2)}$.
 - Příklad uspořádaného prefixového kódu γ pro kódování pěti nejčastějších anglických slov. Vstupní abecedu tvoří slova $W = \{A, AND, OF, THE, TO\}$, kterým jsou přiřazena kódová slova z abecedy $\{0,1\}$. Protože žádné kódové slovo není prefixem jiného, jedná se o prefixový kód.


b	$\gamma(b)$
A	000
AND	001
OF	01
THE	10
TO	11

Stromová reprezentace kódování

- Kód je možné reprezentovat pomocí n -árního stromu s ohodnocenými hranami, kde
 - $n = |\Gamma|$ a listy (nebo uzly v případě kódu, který není prefixový) odpovídají symbolům zdrojové abecedy.
 - Každé hraně je přiřazen symbol kódové abecedy. Spojením symbolů po cestě od kořene směrem k listu (nebo uzlu) získáme kódovou značku přiřazenou symbolu příslušejícímu listu (nebo uzlu).
- Podmínka, že se jedná o prefixové kódování implikuje, že
 - žádné kódové slovo není předchůdcem jiného kódového slova a tudíž kódové slovo musí odpovídat listům. Počet listů je roven $|\Sigma|$.
- Hloubka stromu odpovídá délce nejdelšího kódového slova.



Strom pro příklad z přechozího slidu



Strom pro Eliasův gama kód



Stromová reprezentace kódování

■ Prefixová varianta Morseova kódu:

- Pokud zavedeme symbol pauza, kód se stane prefixovým a jednoznačně dekódovatelným.
- Jinou možností je využít nuly jako oddělovače (0 – pauza, 00 – konec symbolu) a jedničku pro vyjádření čárky nebo tečky (1 – tečka, 11 – čárka)

Příklad: A→101100, B→1101010100, C→11010110100, ...

Rětezec CAB se tedy zakóduje jako CAB → 110101101001011001101010100



Stručný úvod do teorie informace

- V předchozí ukázce jsme získali jednoznačně dekódovatelný prefixový kód, který přiřazuje často se vyskytujícím symbolům kratší značky než méně často se vyskytujícím symbolům. Je však tento kód optimální?
- Odpověď na výše uvedenou otázku nám může podat teorie informace, která dovoluje kvantifikovat informaci a redundanci.
 - Intuitivně cítíme, že informace je neuchopitelná matematická veličina, která se nedá přesně definovat, zachytit a měřit.
 - Teorie informace kvantifikuje informaci a ukazuje, jak měřit informaci, takže může odpovědět na otázku „kolik informace je obsaženo v určité části dat?“ přesným číslem.
- Kvantifikování informace je založeno na postřehu, že obsah informace ve sdělení je ekvivalentní míře *překvapení* tímto sdělením.
 - Pokud dostanete zprávu “další slide se týká teorie informace”, tak žádnou novou informaci nedostanete.
 - Pokud však obdržíte zprávu “toto je k teorii informace vše”, jedná se o překvapivou zprávu bez ohledu na počet slov zprávy, nebo jak se cítíte po této informaci.

Informační obsah (self-information)

- Teorií informace se zabýval ve své práci Shannon, který definoval informační obsah určité události (míru překvapení) následovně:
 - Nechť $P(A)$ je pravděpodobnost, že nastane událost A , potom míra překvapení je definována jako
$$i(A) = \log_b \frac{1}{P(A)} = -\log_b P(A)$$
- Volba logaritmu odpovídá intuitivnímu chápání množství informace:
 1. Pokud pravděpodobnost jisté události je malá, pak míra překvapení, pokud událost nastane, je velká.
 - Pokud $P(A) = 1$, pak $\log P(A) = 0$ a hodnota $-\log(x)$ roste se snižující se hodnotou x od 1 směrem k 0.
 2. Pokud máme dva nezávislé jevy A a B , množství informace se sčítá
 - $$i(AB) = \log_b \frac{1}{P(AB)} = \log_b \frac{1}{P(A)P(B)} = \log_b \frac{1}{P(A)} + \log_b \frac{1}{P(B)} = i(A) + i(B)$$
- Jednotka závisí na použitém základu logaritmu b
 - pokud $b=2$, jednotkou je bit; je-li $b=e$, pak se jedná o nat (natural unit of information)

Informační obsah – příklad

- S ohledem na předchozí definici lze informační obsah chápat také jako
 - a) počet bitů nutný pro vyjádření určité informace nebo
 - b) minimální počet otázek ANO/NE, nutných pro získání určité informace.

- **Příklad a) – házení mincí**
 - Dvě možnosti výsledku: padne hlava (H), nebo panna (T), což můžeme vyjádřit jako ano, nebo ne nebo 0, nebo 1, tzn. jedním bitem. Výsledek kteréhokoliv hodu je předem neurčitý a musíme minci hodit, abychom tuto neurčitost vyřešili. Jediným bitem se vyřeší nejistota při házení mince.

 - Ideální mince: Máme dvě události a sice padne hlava $P(H) = 0.5$ a padne panna $P(T) = 0.5$. Z pohledu množství informace jsou obě události ekvivalentní, neboť $i(H) = -\log_2 P(H) = 1$ bit, $i(T) = -\log_2 P(T) = 1$ bit.

 - Cinknutá mince: Předpokládejme např. $P(H) = 1/8$ a $P(T) = 7/8$, pak $i(H) = 3$ bity a $i(T) = 0.193$ bitů. Výskyt hlavy je méně pravděpodobný a nese z matematického hlediska větší množství informace.

Informační obsah – příklad

- S ohledem na předchozí definici lze informační obsah chápat také jako
 - a) počet bitů nutný pro vyjádření určité informace nebo
 - b) minimální počet otázek ANO/NE, nutných pro získání určité informace.

- **Příklad b) – balíček 64 hracích karet**
 - Mějme balíček 64 hracích karet a uvažme případ, kdy A vytáhne jednu kartu a B má uhodnout, která to je. Odhad je číslo mezi 1 a 64. Jaký je minimální počet otázek, nutných pro uhodnutí karty?

 - Dle definice: Nechť X je náhodná veličina nabývající jednu z 64 hodnot, pak $P(X = x) = 1/64$ a tedy $i(X = x) = \log_2 1/64 = 6$ bitů.

 - Intuitivně (implementace): Nejefektivněji se dobereme výsledku aplikací metody *binárního vyhledávání*. K získání výsledku je zapotřebí $\log_2 64 = 6$ otázek.

Informační obsah zdroje informace

- Výsledky předchozích příkladů lze zobecnit na množinu **nezávislých událostí** A_i (typicky zdroj informace $\mathcal{S}$ produkující symboly A_i s pravděpodobnostmi $P(A_i)$), kde výsledek jistého náhodného experimentu můžeme vyjádřit pomocí *průměrného informačního obsahu* jako

$$H = \sum_i P(A_i) i(A_i) = - \sum_i P(A_i) \log_b P(A_i)$$

- Veličina H se nazývá **entropie náhodné veličiny** (*entropie zdroje informace*), kterou zavedl Shannon jako míru neurčitosti, kterou má průměrně jeden symbol zprávy (míru informace, kterou získáme přečtením jednoho symbolu).
 - Pro hod mincí: $H = P(H) \log_2 P(H) + P(T) \log_2 P(T) = 0.5 \log_2 0.5 + 0.5 \log_2 0.5 = 1$ bit
 - Struktura H není zvolena náhodně, jedná se o funkci splňující axiomy míry neurčitosti, H je pozitivní, spojitá, symetrická a koherentní a až na multiplikativní konstantu existuje pouze jediná.
- **Věta o minimální entropii:**
 - Nejmenší entropie je $H(\mathcal{S}) = 0$ a té nabývá zdroj zpráv obsahující jediný symbol s $P(A_1) = 1$ a $P(A_i) = 0$ pro $i > 1$
- **Věta o maximální entropii:**
 - Největší entropie $H(\mathcal{S}) = \log_2 n$ nabývá zdroj právě když má rovnoměrné rozdělení pravděpodobností $1/n$.

Informační obsah zdroje informace – příklad

- Uvažujme náhodnou veličinu $\mathcal{A}$ s oborem hodnot $M=\{a_1, a_2, a_3, \dots, a_8\}$, která vykazuje vlastnosti rovnoměrného pravděpodobnostního rozložení.

– Platí $P(a_i) = 1/8$ a tedy

$$H(\mathcal{A}) = - \sum_{i=1}^8 P(a_i) \log_2 P(a_i) = \sum_{i=1}^8 \frac{1}{8} \log_2 8 = 3$$

- Nyní uvažujme náhodnou veličinu $\mathcal{A}$ se stejným oborem hodnot ale pravděpodobností jednotlivých prvků $(P(a_1), P(a_2), \dots, P(a_8)) = (1/2, 1/4, 1/8, 1/16, 1/64, 1/64, 1/64, 1/64)$

– Entropie náhodné veličiny $\mathcal{A}$ je nyní rovna

$$H(\mathcal{A}) = - \sum_{i=1}^8 P(a_i) \log_2 P(a_i) = \frac{1}{2} \log_2 2 + \frac{1}{4} \log_2 4 + \frac{1}{8} \log_2 8 + \frac{1}{16} \log_2 16 + \frac{4}{64} \log_2 64 = 2$$

- Tento výsledek už tak zcela intuitivní není. Říká nám, že jsme schopni 8 rozdílných prvků popsat pouze dvěma bity. Jak toho ovšem můžeme dosáhnout?

Informační obsah obecného zdroje informace

- Předchozí definice platí pouze pro zdroj informace, který produkuje symboly, které jsou nezávislé a vykazují charakter stejného pravděpodobnostního rozložení (*angl. independent and identically distributed, i.i.d.*).
- Pro obecný zdroj informace $\mathcal{S}$ s abecedou $\mathcal{A} = \{1, 2, \dots, m\}$ generující zprávu tvořenou posloupností symbolů $X_1, X_2, \dots, X_n$ z množiny $\mathcal{A}$, kde $X_i(j) = j$ je náhodná proměnná, je **entropie zdroje** $H(\mathcal{S})$ dána vztahem

$$H(\mathcal{S}) = \lim_{n \rightarrow \infty} \frac{1}{n} G_n$$

- kde G_n odpovídá entropii posloupnosti $X_1, X_2, \dots, X_n$

$$G_n = - \sum_{i_1, i_2, \dots, i_n} P(X_1 = i_1, X_2 = i_2, \dots, X_n = i_n) \log_2 P(X_1 = i_1, X_2 = i_2, \dots, X_n = i_n)$$

$$G_n = - \sum_{i_1=1}^m \sum_{i_2=1}^m \dots \sum_{i_n=1}^m P(X_1 = i_1, X_2 = i_2, \dots, X_n = i_n) \log_2 P(X_1 = i_1, X_2 = i_2, \dots, X_n = i_n)$$

Informační obsah zdroje informace – entropie prvního řádu

- Pokud je výskyt každého symbolu nezávislý a stejně pravděpodobnostně rozložený (i.i.d.), pak $X_i = X_1 = X$ a tedy

$$H(\mathcal{S}) = -\frac{1}{n}n \sum_{i_1=1}^m P(X_1 = i_1) \log_2 P(X_1 = i_1) = H(X) = -\sum_{i=1}^m P(i) \log_2 P(i)$$

- Vztah odpovídá definici Shannonovy entropie a je běžně označován jako **entropie prvního řádu** (angl. first-order entropy).

Odvození

$$G_n = - \sum_{i_1, i_2, \dots, i_n} P(X_1 = i_1, X_2 = i_2, \dots, X_n = i_n) \log_2 P(X_1 = i_1, X_2 = i_2, \dots, X_n = i_n)$$

$$P(X_1 = i_1, X_2 = i_2, \dots, X_n = i_n) = P(X_1 = i_1)P(X_2 = i_2) \cdots P(X_n = i_n) = \prod_{i=1}^n P(X_i = i_i)$$

$$H(\mathcal{S}) = \lim_{n \rightarrow \infty} \frac{1}{n} G_n = H(X)$$

$$G_n = \sum_{i=1}^n \left(- \sum_{i_i} P(X_i = i_i) \log_2 P(X_i = i_i) \right) = \sum_{i=1}^n H(X) = nH(X)$$

Informační obsah zdroje informace – podmíněná entropie

- Pravděpodobnosti jednotlivých událostí jsou typicky závislé na kontextu C , ve kterém se vyskytly.
- Věta o podmíněné entropii: pokud je distribuce symbolů $\mathcal{S}$ nezávislá na kontextu C , pak platí, že $H(\mathcal{S}|C) = H(\mathcal{S})$. V opačném případě platí že $H(\mathcal{S}|C) < H(\mathcal{S})$
 - Znalost kontextu dovoluje zpřesnit pravděpodobnosti a snížit entropii.
- Pokud je výskyt X_1 závislý na výskytu X_2 , pak hovoříme o **podmíněné entropii** náhodné proměnné X_1 v závislosti na X_2 , kterou lze vyjádřit jako

$$H(X_1|X_2) = \sum_{i_2=1}^m P(i_2)H(X_1|X_2 = i_2) = - \sum_{i_2=1}^m P(i_2) \sum_{i_1=1}^m P(i_1|i_2) \log_2 P(i_1|i_2)$$

- Podmíněná entropie odpovídá entropii zdroje pokud uvažujeme Markovův řetězec 1. řádu, kde $X_1 = X_n$ a $X_2 = X_{n-1}$, tj. pravděpodobnost výskytu n -tého symbolu závisí na předchozím symbolu.

Vsuvka - Markovovy modely


- Závislost v datech lze popsat pomocí Markovských modelů.
 - Pro účely komprese nás zajímá zejména diskrétní Markovský řetězec.
- Posloupnost náhodných veličin $\{X_n | n \in \mathbb{N}, X_n \in \Sigma\}$ tvoří **diskrétní Markovský řetězec k -tého řádu**, jestliže platí

$$P(X_n | X_{n-1}, \dots, X_{n-k}) = P(X_n | X_{n-1}, \dots, X_{n-k}, \dots)$$

- Znalost předchozích k symbolů je ekvivalentní znalosti celé historie.
- Hodnoty $\{X_{n-1}, \dots, X_{n-k}\}$ odpovídají stavu procesu.
- Počet stavů modelu je roven $|\Sigma|^k$
- Nejčastěji se používá model prvního řádu, kde platí

$$P(X_n | X_{n-1}) = P(X_n | X_{n-1}, X_{n-2}, X_{n-3}, \dots)$$

- Příklad: reprezentace pro $\Sigma = \{b, w\}$,



- pokud $P(S_w)$ a $P(S_b)$ je pravděpodobnost, že se nacházíme ve stavu S_w a S_b , pak $H = P(S_w)H(S_w) + P(S_b)H(S_b)$, kde $H(S_w) = -P(b|w) \log P(b|w) - P(w|w) \log P(w|w)$ a $P(w|w) = 1 - P(b|w)$

Vsuvka - Markovovy modely

Příklad: $x_1 x_2 \dots x_{10} = aababbabaa$

- Předpokládejme nezávislý výskyt a a b a stejné rozdělení pravděpodobností:

- $P(a) = 6/10, P(b) = 4/10$
- $H = -P(a)\log_2 P(a) - P(b)\log_2 P(b) = 0.971$ bitů/symbol

- Předpokládejme Markovův model 1. řádu:

- $P(a) = 5/9, P(b) = 4/9, P(a|a) = 2/5, P(b|a) = 3/5, P(a|b) = 3/4, P(b|b) = 1/4$, pak
- $H = P(a)H(X|a) + P(b)H(X|b) = P(a)(-P(a|a)\log_2 P(a|a) - P(b|a)\log_2 P(b|a)) + P(b)(-P(a|b)\log_2 P(a|b) - P(b|b)\log_2 P(b|b)) = 0.9$ bitů/symbol

- Předpokládejme Markovův model 2. řádu:

- $P(aa) = \frac{1}{8}, P(ab) = \frac{3}{8}, P(ba) = \frac{3}{8}, P(bb) = \frac{1}{8}, P(a|aa) = 0, P(b|bb) = 0,$
 $P(b|aa) = 1, P(a|ab) = \frac{2}{3}, P(b|ab) = \frac{1}{3}, P(a|ba) = \frac{1}{3}, P(b|ba) = \frac{2}{3}, P(a|bb) = 1$
- $H = \sum_{x_1 x_2 = aa}^{bb} P(x_1 x_2) H(X|x_1 x_2) = \sum_{x_1 x_2 = aa}^{bb} P(x_1 x_2) (-\sum_{x_3 = a, b} P(x_3|x_1 x_2) \log_2 P(x_3|x_1 x_2))$
 $= 0.689$ bitů/symbol

Vztah entropie a kódování

- Necht' Σ, Γ jsou dvě konečné abecedy symbolů, $|\Gamma| = D$, a Σ^* a Γ^* množina všech řetězců. Předpokládejme, že X je náhodná veličina i.i.d. nabývající hodnot z Σ a dále, že f je jednoznačně dekódovatelné kódování $\Sigma^* \rightarrow \Gamma^*$. Necht' $\mathcal{S}$ je náhodná veličina odpovídající délce kódových slov $f(X)$.
- **Shannonova věta o kódování** bez šumu (Shannon, 1948): Pokud f je optimální kódování z hlediska průměrné délky kódu, tj. má minimální průměrnou délku kódování pro X , kterou označíme $L_{\min} = \langle f \rangle = \mathbb{E}[\mathcal{S}]$, pak

$$\frac{H(X)}{\log_2 D} \leq L_{\min} < \frac{H(X)}{\log_2 D} + 1$$

- Hodnota $\log_2 D$ odpovídá maximální entropii v abecedě o D prvcích
- Důsledek: Optimální binární prefixové kódování f má průměrnou délku větší nebo rovnu entropii zdroje $\mathcal{S}$, tj. $L_{\min} \geq H(\mathcal{S})$, a přinejhorším $H(\mathcal{S}) + 1$
 - Entropie nultého řádu odpovídá teoretickému minimu délky kódování, pokud uvažujeme znalost pravděpodobnosti výskytu jednotlivých symbolů a předpokládáme jejich nezávislost a stejné rozdělení.

Redundance kódování

- S pomocí předchozí věty lze definovat redundanci kódování následovně.
- DEFINICE: *Redundance kódování* R odpovídá rozdílu mezi průměrnou délkou kódování f a entropií zdroje $H(\mathcal{S})$, tedy

$$R = \langle f \rangle - \frac{H(\mathcal{S})}{\log_2 D}$$

- Problém *nalezení optimálního kódování* lze formulovat následovně: Máme-li danu zdrojovou abecedu Σ a abecedu kódových symbolů Γ , cílem je nalézt jednoznačně dekódovatelné kódování $f: \Sigma^* \rightarrow \Gamma^*$ takové, pro které se R blíží nule (tzn. jehož průměrná délka je nejmenší možná).
 - Lze zobecnit, pokud budeme uvažovat, že kódování jednotlivých symbolů má různou cenu (náročnost).

Vztah entropie a kódování – příklad

- **Určení entropie zdroje je** obecně **problematické**, neboť předem nevíme, jakým způsobem bude zdroj symboly generovat.
 - Pro přesné určení hodnoty bychom ideálně potřebovali nekonečně mnoho dlouhých vzorků a dále informaci o struktuře dat.
 - Entropii můžeme jenom odhadovat na základě znalosti určitého vzorku dat a našem předpokladu o struktuře problému.
- **Příklad: mějme zdroj, který vygeneroval sekvenci 1 2 3 2 3 4 5 4 5 6 7 8 9 8 9 10**
 - Platí, že $P(1) = P(6) = P(7) = P(10) = 1/16$, $P(2) = P(3) = P(4) = P(5) = P(8) = P(9) = 2/16$
 - Pokud budeme předpokládat, že sekvence je i.i.d., entropie odpovídá entropii prvního řádu
$$H = \sum_{i=1}^{10} P(i) \log_2 P(i) = 3.25 \text{ bitů}$$
 - A tedy nejlepší kódování, které můžeme použít, bude mít průměrnou délku slov alespoň 3.25 bitů.
- **Znalost struktury dat může pomoci redukovat entropii**
 - Pokud však použijeme model založený na diferenci sousedních vzorků, dostáváme sekvenci 1 1 1 -1 1 1 1 -1 1 1 1 1 -1 1 1. Tato sekvence je tvořena pouze dvěma symboly $P(1)=13/16$ a $P(-1)=3/16$ a entropie bude $H = 0.7$ bitů.
 - V praxi není možné dosáhnout 0.7 bitů na symbol neboť potřebujeme ještě znát hodnotu prvního prvku, abychom mohli sekvenci rekonstruovat.

Vztah entropie a kódování – rozšíření zdroje (source extension)

- Produkuje-li zdroj informace $\mathcal{S}$ symboly $a_1, a_2, \dots, a_k$ s pravděpodobnostmi výskytu $p_i = P(a_i)$, potom **n-násobným rozšířením zdroje** $\mathcal{S}$ nazýváme zdroj $\mathcal{S}^n$, jehož symboly jsou všechna slova $a_{i_1} a_{i_2} \dots a_{i_n}$ délky n původní abecedy.
 - V případě i.i.d., platí $P(a_{i_1} a_{i_2} \dots a_{i_n}) = P(a_{i_1})P(a_{i_2}) \dots P(a_{i_n})$,
jinak $P(a_{i_1} a_{i_2} \dots a_{i_n}) = P(a_{i_n} | a_{i_1} \dots a_{i_{n-1}})$
- **VĚTA:** Entropie rozšířeného zdroje je rovna $H(\mathcal{S}^n) = nH(\mathcal{S})$.
 - Při n-násobném rozšíření se nemění množství informace obsažené v jednom symbolu. Pracujeme ale s n-ticemi a proto entropie musí být n-krát větší.
- **Příklad pro sekvenci 1 2 1 2 3 3 3 3 1 2 3 3 3 3 1 2 3 3 1 2**
 - Zkoumáme-li symboly izolovaně, dostáváme $P(1) = P(2) = 1/4$, $P(3) = 1/2$ a entropie je $H(\mathcal{S})=1.5$ bitů.
 - Jinou možností je podívat se na entropii Markovova modelu 1. řádu, tj. $P(1)=4/19$, $P(2)=5/19$, $P(3)=10/19$, $P(1|2)=1/4$, $P(1|3)=3/4$, $P(2|1)=1$, $P(3|2)=3/10$, $P(3|3)=7/10$ $H(\mathcal{S})=0.63$ bitů.
 - Vidíme však, že za symbolem 1 s velkou pravděpodobností následuje symbol 2. A dále, že za symbolem 3 následuje další symbol 3. Po rozšíření na dvojice symbolů dostáváme pouze dva typy symbolů a sice 1 2 a 3 3 s pravděpodobnostmi výskytu $P(1\ 2)=1/2$ a $P(3\ 3)=1/2$. Entropie je rovna $H(\mathcal{S}^2)=1$ bit, tzn. 0.5 bitu na symbol.

Entropie rozšířeného zdroje

- Příklad: odvození $H(\mathcal{S}^n) = nH(\mathcal{S})$ pro $n = 2$:
 - $\Sigma = \{a_0, \dots, a_n\}$
 - $H(\mathcal{S}) = -\sum_i P(a_i) \log_2 P(a_i)$
 - $H(\mathcal{S}^2) = -\sum_i \sum_j P(a_i a_j) \log_2 P(a_i a_j)$
 - v případě i.i.d. sekvence platí, že $P(a_i a_j) = P(a_i)P(a_j)$

$$H(\mathcal{S}^2) = -\sum_i \sum_j P(i)P(j) \log_2 P(i)P(j)$$

Existence optimálního kódování

- Změnou zdrojové abecedy na n -tice (nezávislých) symbolů původní abecedy (tj. uvažujeme rozšířený zdroj) se lze s průměrnou délkou kódování libovolně přiblížit entropii zdroje pro $n \rightarrow \infty$.
- Důkaz (binární kódová abeceda):
 - Dle Shannonovy věty o kódování platí pro $\overline{L_{\min}} = \langle C(\mathcal{S}^n) \rangle$:

$$H(\mathcal{S}^n) \leq \overline{L_{\min}} < H(\mathcal{S}^n) + 1$$

- Protože $H(\mathcal{S}^n) = nH(\mathcal{S})$, tak platí

$$nH(\mathcal{S}) \leq \overline{L_{\min}} < nH(\mathcal{S}) + 1$$

a tedy

$$H(\mathcal{S}) \leq \frac{\overline{L_{\min}}}{n} < H(\mathcal{S}) + \frac{1}{n}$$

- Počet bitů na symbol $L_{\min} = \frac{\overline{L_{\min}}}{n}$ a tedy

$$H(\mathcal{S}) \leq L_{\min} < H(\mathcal{S}) + \frac{1}{n}$$

Optimální kódování

- Hlavní teorém, který dokázal Shannon v podstatě říká, že existují téměř optimální kompresory (zvané *entropické kodéry*), ale neříká, jak je vytvořit.
 - Aritmetické kódování je příkladem entropického kodéru, stejně tak jako slovníkové algoritmy, ty však vyžadují pro práci na entropické úrovni obrovské objemy dat.
- Shannonova entropie (zdroje, posloupnosti symbolů) při uvažování (více) závislostí mezi výskyty symbolů je vždy menší nebo rovna entropii při nezávislém (méně závislém) výskytu symbolů, tzn. *entropie je závislá na uvažovaném modelu struktury dat*.
- Uvažováním závislostí mezi výskyty symbolů posloupnosti nesnižujeme skutečnou entropii zdroje dat.
 - Entropie je vlastností zdroje a je stejná pro všechna data ze zdroje.
 - Snižujeme náš odhad této entropie uvažováním delších n-tic symbolu dat a závislostí mezi výskyty symbolu v modelu
- Pozor na velikost vzorku dat a řád modelu.
 - Nedostatek informace může vést ke zkreslení pravděpodobnostního rozdělení

Vsuvka - redundancy dat


- Entropie dat závisí na jednotlivých pravděpodobnostech p_i , a je největší v případě, když je všech n pravděpodobností shodných, tj. $p_i = \frac{1}{n}$. Tato skutečnost je použita k definování redundancy dat.
- DEFINICE: **Redundance dat** R odpovídá rozdílu mezi nejvyšší možnou entropií množiny symbolů $\mathcal{A}$ a její skutečnou entropií. Tedy

$$R = H_{max}(\mathcal{A}) - H(\mathcal{A}) = \log_2 n + \sum_{i=1}^n p_i \log_2 p_i \quad n = |\mathcal{A}|$$


- Pro zcela komprimovaná data (tj. bez redundancy) vykazující charakter náhodných dat je $R = 0$

Příklad: entropie anglického textu

- Jaký je informační obsah v angličtině, tj. mez, na kterou se může anglický text komprimovat?
 - Pro určení informačního obsahu použijeme střední počet bitů na znak.
- Předpokládáme-li **stejnou pravděpodobnost všech symbolů**, vlastní kód pro každý znak a 96 symbolů (počet na standardní klávesnici)
 - každý znak potřebuje $\log_2 96 = 6.6$ bitů na znak.
- Pokud použijeme pravděpodobnosti symbolů podle anglického textového korpusu
 - dostaneme entropii 4.5 bitů/znak.
- Pokud text rozdělíme na **osmice znaků** a změříme entropii těchto bloků, dostaneme
 - entropii kolem 14 bitů, tj. přibližně 1.75 bitů/znak.



Jurgens, A. Entropy in Written English 2016
(Corpus of 155 billion words googlebooks.byu.edu)



Příklad: entropie anglického textu

Četnost výskytu bigramů v anglickém textu

AA	BA	CA	DA	EA	FA	GA	HA	IA	JA	KA	LA	MA	NA	OA	PA	QA	RA	SA	TA	UA	VA	WA	XA	YA	ZA
AB	BB	CB	DB	EB	FB	GB	HB	IB	JB	KB	LB	MB	NB	OB	PB	QB	RB	SB	TB	UB	VB	WB	XB	YB	ZB
AC	BC	CC	DC	EC	FC	GC	HC	IC	JC	KC	LC	MC	NC	OC	PC	QC	RC	SC	TC	UC	VC	WC	XC	YC	ZC
AD	BD	CD	DD	ED	FD	GD	HD	ID	JD	KD	LD	MD	ND	OD	PD	QD	RD	SD	TD	UD	VD	WD	XD	YD	ZD
AE	BE	CE	DE	EE	FE	GE	HE	IE	JE	KE	LE	ME	NE	OE	PE	QE	RE	SE	TE	UE	VE	WE	XE	YE	ZE
AF	BF	CF	DF	EF	FF	GF	HF	IF	JF	KF	LF	MF	NF	OF	PF	QF	RF	SF	TF	UF	VF	WF	XF	YF	ZF
AG	BG	CG	DG	EG	FG	GG	HG	IG	JG	KG	LG	MG	NG	OG	PG	QG	RG	SG	TG	UG	VG	WG	XG	YG	ZG
AH	BH	CH	DH	EH	FH	GH	HH	IH	JH	KH	LH	MH	NH	OH	PH	QH	RH	SH	TH	UH	VH	WH	XH	YH	ZH
AI	BI	CI	DI	EI	FI	GI	HI	II	JI	KI	LI	MI	NI	OI	PI	QI	RI	SI	TI	UI	VI	WI	XI	YI	ZI
AJ	BJ	CJ	DJ	EJ	FJ	GJ	HJ	IJ	JJ	KJ	LJ	MJ	NJ	OJ	PJ	QJ	RJ	SJ	TJ	UJ	VJ	WJ	XJ	YJ	ZJ
AK	BK	CK	DK	EK	FK	GK	HK	IK	JK	KK	LK	MK	NK	OK	PK	QK	RK	SK	TK	UK	VK	WK	XK	YK	ZK
AL	BL	CL	DL	EL	FL	GL	HL	IL	JL	KL	LL	ML	NL	OL	PL	QL	RL	SL	TL	UL	VL	WL	XL	YL	ZL
AM	BM	CM	DM	EM	FM	GM	HM	IM	JM	KM	LM	MM	NM	OM	PM	QM	RM	SM	TM	UM	VM	WM	XM	YM	ZM
AN	BN	CN	DN	EN	FN	GN	HN	IN	JN	KN	LN	MN	NN	ON	PN	QN	RN	SN	TN	UN	VN	WN	XN	YN	ZN
AO	BO	CO	DO	EO	FO	GO	HO	IO	JO	KO	LO	MO	NO	OO	PO	QO	RO	SO	TO	UO	VO	WO	XO	YO	ZO
AP	BP	CP	DP	EP	FP	GP	HP	IP	JP	KP	LP	MP	NP	OP	PP	QP	RP	SP	TP	UP	VP	WP	XP	YP	ZP
AQ	BQ	CQ	DQ	EQ	FQ	GQ	HQ	IQ	JQ	KQ	LQ	MQ	NQ	OQ	PQ	QQ	RQ	SQ	TQ	UQ	VQ	WQ	XQ	YQ	ZQ
AR	BR	CR	DR	ER	FR	GR	HR	IR	JR	KR	LR	MR	NR	OR	PR	QR	RR	SR	TR	UR	VR	WR	XR	YR	ZR
AS	BS	CS	DS	ES	FS	GS	HS	IS	JS	KS	LS	MS	NS	OS	PS	QS	RS	SS	TS	US	VS	WS	XS	YS	ZS
AT	BT	CT	DT	ET	FT	GT	HT	IT	JT	KT	LT	MT	NT	OT	PT	QT	RT	ST	TT	UT	VT	WT	XT	YT	ZT
AU	BU	CU	DU	EU	FU	GU	HU	IU	JU	KU	LU	MU	NU	OU	PU	QU	RU	SU	TU	UU	VU	WU	XU	YU	ZU
AV	BV	CV	DV	EV	FV	GV	HV	IV	JV	KV	LV	MV	NV	OV	PV	QV	RV	SV	TV	UV	VV	WV	XV	YV	ZV
AW	BW	CW	DW	EW	FW	GW	HW	IW	JW	KW	LW	MW	NW	OW	PW	QW	RW	SW	TW	UW	VW	WW	XW	YW	ZW
AX	BX	CX	DX	EX	FX	GX	HX	IX	JX	KX	LX	MX	NX	OX	PX	QX	RX	SX	TX	UX	VX	WX	XX	YX	ZX
AY	BY	CY	DY	EY	FY	GY	HY	IY	JY	KY	LY	MY	NY	OY	PY	QY	RY	SY	TY	UY	VY	WY	XY	YY	ZY
AZ	BZ	CZ	DZ	EZ	FZ	GZ	HZ	IZ	JZ	KZ	LZ	MZ	NZ	OZ	PZ	QZ	RZ	SZ	TZ	UZ	VZ	WZ	XZ	YZ	ZZ

Nejčtenější n-gramy

1	2grams	3grams	4-grams	5-grams	6-grams	7-grams	8-grams	9-grams
e	th	the	tion	ation	ations	present	differen	different
t	he	and	atio	tions	rational	ational	national	governmen
a	in	ing	that	which	tional	through	consider	overnment
o	er	ion	ther	ction	nation	between	position	formation
i	an	tio	with	other	ection	ication	ifferent	character
n	re	ent	ment	their	cation	differe	governme	velopmen
s	on	ati	ions	there	lation	ifferen	vernment	developme
r	at	for	this	ition	though	general	overnmen	developmen
h	en	her	here	ement	presen	because	interest	condition
l	nd	ter	from	inter	tation	develop	importan	important
d	ti	hat	ould	ional	should	america	ormation	articular
c	es	tha	ting	ratio	resent	however	formatio	particula
u	or	ere	hich	would	genera	eration	relation	represent
m	te	ate	whic	tiona	dition	nationa	question	individua
f	of	his	ctio	these	ationa	conside	american	ndividual
p	ed	con	ence	state	produc	onsider	characte	relations
g	is	res	have	natio	throug	ference	haracter	political
w	it	ver	othe	thing	hrough	positio	articula	informati
y	al	all	ight	under	etween	osition	possible	nformatio
b	ar	ons	sion	ssion	between	ization	children	universit
v	st	nce	ever	ectio	differ	fferent	elopmen	following
k	to	men	ical	catio	icatio	without	velopmen	experien
x	nt	ith	they	latio	people	ernment	developm	stitution
j	ng	ted	inte	about	iffere	vernmen	velopme	xperience
q	se	ers	ough	count	fferen	overnme	conditio	education
z	ha	pro	ance	ments	struct	governm	ondition	roduction

Kódování s proměnnou délkou kódových slov – motivace

- Uvažujme čtyři symboly $W=\{a_1, a_2, a_3, a_4\}$. Pokud se vyskytují v našich datových řetězcích se shodnými pravděpodobnostmi, pak entropie dat H a tudíž i nejmenší průměrný počet bitů potřebný na reprezentaci symbolu je
$$\langle f \rangle = -4(0.25 \log_2 0.25) = 2.$$
 - Symbolům můžeme přiřadit čtyři 2-bitové kódové kombinace 00, 01, 10 a 11. Protože pravděpodobnosti jsou shodné, redundance je nulová a data se pod 2 bity/symbol nedají zredukovat.
- Nyní uvažme případ $p(a_1)=0.49$, $p(a_2)=0.25$, $p(a_3)=0.25$ a $p(a_4)=0.01$. Nyní mají data entropii $H = -(0.49 \log_2 0.49 + 0.25 \log_2 0.25 + 0.25 \log_2 0.25 + 0.01 \log_2 0.01) \approx -(-0.05 - 0.5 - 0.5 - 0.066) = 1.57$. Nejmenší průměrný počet bitů potřebných k reprezentaci jednotlivých symbolů klesl na 1.57.
 - Je zřejmé, že když přidělíme symbolům 2-bitové kombinace, nemůžeme dosáhnout průměrné délky kódování menší než 2, redundance bude $R = \log_2 4 - 1.57 = 0.43$.
- Abychom se přiblížili entropii, jedinou možností je přidělovat symbolům jednoznačně dekódovatelné *kódy s proměnnou délkou*. Jak ale volit délky a obsah kódových slov?

Kraft-McMillanova nerovnost

- Kraft-McMillanova nerovnost tvrdí, že jednoznačně dekódovatelné kódování s předepsanou délkou slov existuje právě tehdy, když existuje prefixový kód se stejnou délkou slov.
 - dává do vztahu délky kódových slov jednoznačně dekódovatelných kódů a umožňuje omezit naši pozornost pouze na prefixové kódy.
- McMillanova nerovnost (McMillan, 1956)
 - Jednoznačně dekódovatelný kód obsahující n kódových slov, která mají délku L_i , jehož kódová slova jsou generována nad abecedou Γ o mohutnosti $|\Gamma| = D$, existuje právě tehdy, když

$$\sum_{i=1}^n D^{-L_i} \leq 1$$

- Kraftova nerovnost (Kraft, 1949)
 - Je-li Γ abeceda mohutnosti D a máme danu množinu n celých čísel $(L_1, L_2, \dots, L_n)$, pak nutná a dostatečná podmínka, že existuje prefixové kódování jehož kódová slova mají délku odpovídající L_i je, že platí

$$\sum_{i=1}^n D^{-L_i} \leq 1$$

Kraft-McMillanova nerovnost – komentář

- Pokud máme danu množinu délek $(L_1, L_2, \dots, L_n)$ splňující podmínku nerovnosti, pak věta tvrdí, že existuje prefixové kódování s kódovými slovy stejných délek.
 - Př. 1: Mějme $l = (1, 2, 3)$, můžeme ověřit, že $2^{-1} + 2^{-2} + 2^{-3} = 7/8$, což je hodnota menší než 1. Příkladem prefixového kódování může být (0,10,110).

- Jednoznačně dekódovatelné kódování splňující podmínku nerovnosti nemusí být nutně prefixové

- Př. 2: kódování (0, 01, 11) splňuje podmínku, neboť $2^{-1} + 2^{-2} + 2^{-2} = 1$, ale není prefixové. Prefixovým kódováním se stejnými délkami kódu je (0,10,11).
- Př. 3: kódování slovy fixní délky (např. binární kód) je jednoznačně dekódovatelné, neboť pro n symbolů je $L_i = \lceil \log_2 n \rceil$ ($L_i = \log_2 n$, je-li n mocnina 2) a suma je rovna

$$\sum_{i=1}^n 2^{-L_i} = \sum_{i=1}^n 2^{-\log_2 n} = \sum_{i=1}^n \frac{1}{n} = 1$$

- Nerovnost lze pochopit, pokud se podíváme na vlastnosti reprezentace prefixového kódování pomocí n -árního stromu
 - viz příklad dále





Princip konstrukce prefixového kódu – důkaz Kraftovy nerovnosti

- Při konstrukci kódování stačí znát délky kódových slov, která chceme použít.
 - Pomocí délek pak sestavíme prefixové kódování. Není nutné se zabývat jiným typem kódování, protože dle McMillanovy věty jsou prefixové kódování stejně obecné jako ostatní jednoznačně dekódovatelné kódování. Způsob volby délek plyne z Kraftovy nerovnosti.
- Důkaz Kraftovy nerovnosti pro binární kódování:
 - Předpokládejme, že délky $L_1, L_2, \dots, L_r$ jsou uspořádány tak, aby tvořily neklesající posloupnost $L_1 \leq L_2 \leq \dots \leq L_r$
 - Nejprve zvolíme kódové slovo $f(a_1)$ délky L_1 . Poté zvolíme libovolné slovo $f(a_2)$ délky L_2 , které nemá prefix $f(a_1)$ a tento postup opakujeme až nakonec zvolíme slovo $f(a_r)$.
 - V případě binárního kódu máme 2^{L_1} slov délky L_1 . Při volbě $f(a_2)$ se musíme vyhnout slovům délky L_2 mající prefix $f(a_1)$. Takových je $2^{L_2-L_1}$, protože každé takové slovo vznikne doplněním $L_2 - L_1$ bitů k prefixu. Platí $2^{L_2-L_1} < 2^{L_2}$. Při volbě slova délky L_3 se musíme vyhnout všem slovům s prefixem $f(a_1)$ a prefixem $f(a_2)$, takových je $2^{L_3-L_1}$ a $2^{L_3-L_2}$. Potřebujeme aby celkový počet slov délky L_3 byl alespoň o 1 větší než počet slov, kterým se vyhýbáme, tj. $2^{L_3-L_1} + 2^{L_3-L_2} + 1 \leq 2^{L_3}$, což po úpravě dává $2^{-L_1} + 2^{-L_2} + 2^{-L_3} \leq 1$
 - Abychom mohli dojít až do konce, je zřejmé, že musí platit $2^{-L_1} + 2^{-L_2} + \dots + 2^{-L_r} \leq 1$

Kraft-McMillanova nerovnost – příklad konstrukce kódu

- Mějme zkonstruovat co možná nejkratší prefixové kódování f pro $W=\{a_1, \dots, a_5\}$ a $\Sigma=\{0,1\}$.
 - Zvolme $f(a_1)=0$. Pak ale ostatní kódy musí začínat symbolem 1, aby se jednalo o prefixový kód. Přiřadíme kódy následovně: $\{0, 10, 110, 1110, 1111\}$. Dostáváme délky $L=\{1,2,3,4,4\}$, čímž splníme podmínku nerovnosti neboť $2^{-1} + 2^{-2} + 2^{-3} + 2^{-4} + 2^{-4} = 1$.
 - Tím, že jsme na počátku zvolili $f(a_1)=0$, jsme vyčerpali celou levou část binárního stromu a zbylé kódové značky tudíž musí ležet v pravé polovině. Volbou $a_2=10$ jsme vyčerpali polovinu pravé poloviny, tudíž $1/4$ kapacity binárního stromu.
 - Pokud bychom chtěli získat kódování pro délky $L=\{1,2,3,3,4\}$, zjistíme, že to není možné neboť jednak neplatí nerovnost ($2^{-1} + 2^{-2} + 2^{-3} + 2^{-3} + 2^{-4} = 1.0625$) a jednak není ve stromu kapacita pro symbol a_5 .



Kraft-McMillanova nerovnost – důsledek

- Důsledek: Lze dokázat, že pokud máme abecedu n symbolů a kódové slovo některého ze symbolů zkrátíme určitým faktorem, tak jiné se musí prodloužit o větší faktor.

- Příklad:

- Uvažujme binární kódování s pevnou délkou kódových značek, kde první symbol zkrátíme, druhý prodloužíme a ostatní symboly zakódujeme pomocí $\log_2 n$ bitů. Označme délky $L_1 = \log_2 n - a$, $L_2 = \log_2 n + b$, a $L_3 = L_4 = \dots = L_n = \log_2 n$, kde a and b jsou kladné hodnoty. Pro součet platí, že

$$\sum_{i=1}^n 2^{-L_i} = 2^{-L_1} + 2^{-L_2} + \sum_{i=3}^n 2^{-\log_2 n} = 2^{-\log_2 n + a} + 2^{-\log_2 n - b} + \sum_{i=1}^n 2^{-\log_2 n} - 2 \cdot 2^{-\log_2 n} = \frac{2^a}{n} + \frac{2^{-b}}{n} + 1 - \frac{2}{n}$$

- Kraft-McMillanova nerovnost vyžaduje, aby platilo $\frac{2^a}{n} + \frac{2^{-b}}{n} + 1 - \frac{2}{n} \leq 1$, tj. $\frac{2^a}{n} + \frac{2^{-b}}{n} - \frac{2}{n} \leq 0$
- Po úpravě dostáváme $b \geq -\log_2(2 - 2^a)$
- Z nerovnosti vyplývá, že $a \leq 1$, jinak by byl výraz $2 - 2^a$ záporný. Protože a odpovídá komprimovanému symbolu, musí se jednat o hodnotu mezi $(0,1]$.
V tomto rozsahu je však b vždy větší než a .

$$a = 1 \rightarrow b \geq -\log_2 0 = \infty$$

$$a = 0.1 \rightarrow b \geq -\log_2(2 - 2^{0.1}) \approx 0.10745$$



Vztah entropie a Kraft-McMillanovy nerovnosti

- Délku kódových slov L_i můžeme definovat jako součet optimální délky dle entropie a hodnoty o kterou je nutné kódovou značku prodloužit, tj. $L_i = -\log_2 P_i + E_i$
- Z definice délky můžeme získat

$$2^{-L_i} = 2^{(\log_2 P_i - E_i)} = \frac{2^{\log_2 P_i}}{2^{E_i}} = \frac{P_i}{2^{E_i}}$$

- Nyní pro jednoduchost předpokládejme, že $E_i = E$,
pak z Kraft-McMillanovy nerovnosti plyne, že

$$1 \geq \sum_{i=1}^n 2^{-L_i} = \sum_{i=1}^n \frac{P_i}{2^E} = \frac{\sum_{i=1}^n P_i}{2^E} = \frac{1}{2^E} \quad , \text{ tj } \quad 2^E \geq 1 \quad , \text{ tj } \quad E \geq 0$$

- Tím jsme ukázali, že délka kódových slov jednoznačně dekódovatelného kódování je větší nebo rovna hodnotě odpovídající entropii.

$$L_i = -\log_2 P_i$$

Návrh optimálního prefixového kódování

- Je-li dána pravděpodobnost výskytu symbolů zdrojové abecedy, pak **problematika návrhu optimálního prefixového kódování** (tj. takového, které má nejmenší možnou průměrnou délku kódových slov) s jednotnou cenou kódování jednotlivých kódových slov kódující vstup symbol po symbolu, **kde jednotlivé výskyty symbolů jsou nezávislé a stejně rozdělené**, je **vyřešený problém** (Huffman, 1952).
- Princip tvorby binárního Huffmanova stromu pro abecedu $\Sigma = (a_1, \dots, a_n)$ a pravděpodobnosti výskytu $P(a_i)$:
 - Nalézt symboly a_1 a a_2 z Σ s nejmenší pravd. a nahradit je novým symbolem a a přiřadit mu pravd. $P(b) = P(a_1) + P(a_2)$. Vytvořit uzel a a přiřadit mu potomky a_1 a a_2 . Pokračovat dále dokud nezůstane jediný symbol. Výsledkem je binární strom odpovídající optimálnímu prefixovému kódu.
- Složitost algoritmu je $O(n \log n)$ nebo $O(n)$ pokud jsou pravděpodobnosti seřazeny.
 - Příklad $\Sigma = \{a, b, c, d, e, f\}$, $P = \frac{1}{18}\{2, 2, 3, 3, 3, 5\}$

a	b	c	d	e	f
2	2	3	3	3	5


ab	c	d	e	f
4	3	3	3	5

ab	c	de	f
4	3	6	5

$(ab)c$	de	f
7	6	5

$(ab)c$	$(de)f$
7	11

$((ab)c)((de)f)$
18




Je získané kódování opravdu optimální?

Návrh optimálního prefixového kódování

$$2^{-L_i} = \hat{P}_i$$

- Příklad $\Sigma = \{a, b, c, d, e, f\}$, $P = \frac{1}{18}\{2, 2, 3, 3, 3, 5\}$
 - $P = \{0.1\bar{1}, 0.1\bar{1}, 0.1\bar{6}, 0.1\bar{6}, 0.1\bar{6}, 0.2\bar{7}\}$
 - $L = \{3.17, 3.17, 2.58, 2.58, 2.58, 1.85\}$
 - $\hat{L} = \{3, 3, 2, 3, 3, 2\}$
 - $\hat{P} = \{0.125, 0.125, 0.25, 0.125, 0.125, 0.25\}$



Kódování celých čísel a univerzální kódování

- V případě kódování celých čísel hledáme takový předpis, který bude vést na jednoznačně dekódovatelné (tj. prefixové) a univerzální kódování.
- **Kódování je univerzální** právě tehdy, přiřazuje-li vstupním slovům kódová slova tak, že jejich průměrná délka je ohraničena výrazem $c_1(H + c_2)$, kde H odpovídá entropii zdroje dat
 - Uvažujeme-li libovolný zdroj dat s nenulovou entropií, pak univerzální kódování aplikované na tento zdroj má průměrnou délku kódových slov rovnou násobku průměrné délky kódových slov optimálního kódování.
 - Velikosti konstant c_1 a c_2 určují míru redundance (dosažené komprese).
 - Blíží-li se průměrná délka kódových slov entropii, tj. $c_1 = 1$, hovoříme o **asymptoticky optimálním kódování**.
- **Výhody univerzálního kódování**
 - oproti Huffmanovu kódování, které vede také na optimální kódování, není nutné znát přesné pravděpodobnosti s jakými se jednotlivé symboly vyskytují. Postačí uspořádat jednotlivé symboly tak, aby reflektovaly pravděpodobnostní rozložení.
 - kódová slova jsou statická, což zjednodušuje proces kódování i dekódování. Není nutné je konstruovat pro každý blok dat. Statická kódová slova není nutné ukládat do výstupního toku, aby byla umožněna jednoznačná rekonstrukce.

Kódování celých čísel

■ Neuniverzální kódování:

- Unární kód
- Start-step-stop kódy
- Golomb-Riceovy kódy

■ Univerzální kódování:

- Variable-length quantity (VLQ)
- Eliasovo gama, delta (asympt. optimální) a omega kódování (asympt. optimální)
- Exponenciální Golombovy kódy
- Fibonacciho kód
- Levenshteinův kód (asympt. optimální)
- Yamamotovy kódy, Goldbachovy kódy, ...

■ Typicky se jedná o kódování celých nenulových čísel, $\mathbb{N}_1 = \mathbb{N}^+ = \mathbb{N}$.

- předpokládáme $p(n) \geq p(n+1) \geq p(n+2)$ pro $n \in \mathbb{N}$
- Rozšíření na $\mathbb{N}_0 = \mathbb{N} \cup \{0\}$: kódovat hodnotu $n+1$
- Rozšíření na $\pm\mathbb{N}_1$: bijekce $\mathbb{N}_1 \rightarrow \{1, -1, 2, -2, 3, -3, \dots\}$

Unární kódování

- Unární kód je kódování, které reprezentuje přirozené číslo n pomocí
 - n jedniček následovaných jedinou 0 uvažujeme-li $n \geq 0$, nebo alternativně
 - $n - 1$ jedniček následovaných jedinou nulou uvažujeme-li $n > 0$.
- Formálně lze definovat jako kódování $(\Sigma, \mathbb{B}, f)$, kde $\mathbb{B} = \{0,1\}$, $f: \Sigma \rightarrow \mathbb{B}^+$ a buď $\Sigma = \mathbb{N}_0$, $f(n) = 1^n 0$ nebo $\Sigma = \mathbb{N}_1$, $f(n) = 1^{n-1} 0$
 - Alternativně lze prohodit význam jedničky a nuly.

- Tabulka kódových slov pro prvních pět hodnot:

n	Unární kód	Alt. unární kód	Reverzní unár. kód	Alt. rev. unár. Kód
0	-	0	-	1
1	0	10	1	01
2	10	110	01	001
3	110	1110	001	0001
4	1110	11110	0001	00001

Vlastnosti unárního kódování

■ Jednoduchá implementace

```
def unary_encode(n):  
  
    while n > 0:  
        write_bit(1)  
        n = n - 1  
  
    write_bit(0)
```

```
def unary_decode():  
  
    n = 0  
    while read_bit() == 1:  
        n = n + 1  
  
    return n
```

■ Prefixová vlastnost

- Jedná se o bezprostředně dekódovatelné kódování?

■ Použití

- Kód typicky tvoří součást jiných kódování s proměnnou délkou značek (viz Elias).

■ Jak se vypořádat s negativními hodnotami?

- viz bijekce


Optimalita unárního kódování

- Omezíme-li se na variantu $n > 0$, pak kódování je výhodné použít a je optimální tehdy, kdy čísla na vstupu kodéru mají charakter *exponenciálního rozložení pravděpodobnosti* $P(n) = 2^{-n}$.
 - V tomto případě bude kódování stejně efektivní jako Huffmanovo kódování avšak mnohem efektivnější co se složitosti kódování a dekódování týče.
- Příklad: Kódové značky získané pomocí unárního a Huffmanova kódování pro exponenciální rozložení pravděpodobnosti
 - Kódy mají stejnou délku s výjimkou hodnoty 6, kdy $P(6) = 2^{-5} \approx 2^{-6}$ a symbol neodpovídá přesně pravděpodobnosti protože je malý počet symbolů a musí platit, že $\sum_{i=1}^6 P(i) = 1$

n	Prob.	Unary	Huffman
1	2^{-1}	0	0
2	2^{-2}	10	10
3	2^{-3}	110	110
4	2^{-4}	1110	1110
5	2^{-5}	11110	11110
6	2^{-5}	111110	11111

Start-Step-Stop kódování

- Start-Step-Stop kódování je celá třída kódování. Konkrétní podoba funkce f je charakterizována trojicí celočíselných parametrů $(start, step, stop)$.
 - Kódovou značku pro celé číslo n tvoří dvě části – předpona a přípona délky L_s
 - Hodnoty jsou rozděleny do skupin sdružující kódová slova stejné délky
 - Délka kódových slov se postupně prodlužuje ($step > 0$), případně zůstává konstantní ($step = 0$)
 - Počet hodnot ve skupině se postupně zvětšuje ($step > 0$), případně zůstává konstantní ($step = 0$)




- Parametry:
 - Parametr $start$ určuje počáteční délku přípony,
 - Parametr $step$ kolik bitů se přidá v každé skupině, tzn. že délka kódové značky roste o násobky $step$.
 - Parametr $stop$ omezuje maximální délku kódové značky a je volen tak, abychom byli schopni zakódovat požadovaný rozsah. Hodnota $stop$ odpovídá hodnotě $start + k_{max} \cdot step$, kde $k_{max} \in \mathbb{N}$.

Start-Step-Stop kódování

- Pro dané parametry je možné zakódovat hodnotu v rozsahu $0 \leq n < n_{\max}$, kde

$$n_{\max} = \frac{2^{\text{stop}+\text{step}} - 2^{\text{start}}}{2^{\text{step}} - 1}$$

- Kódovou značku pro celé číslo n tvoří dvě části:
 - předpona, která je tvořena modifikací unárního kódu (poslední skupina kódována odlišně) a
 - přípona délky $\text{start} + k \cdot \text{step}$ bitů, která kóduje hodnotu n zmenšenou o počet kódových slov, které předchází první kódovou značku v k -té skupině



Start-Step-Stop kódování

■ Příklad: Start-Step-Stop kód (3,2,9)

- kódové značky jsou organizovány do 4 skupin

Kódové značky pro n v daném rozsahu

Rozsah

0	x_2	x_1	x_0
---	-------	-------	-------

0 – 7

1	0	x_4	x_3	x_2	x_1	x_0
---	---	-------	-------	-------	-------	-------

8 – 39

1	1	0	x_6	x_5	x_4	x_3	x_2	x_1	x_0
---	---	---	-------	-------	-------	-------	-------	-------	-------

40 – 167

1	1	1	x_8	x_7	x_6	x_5	x_4	x_3	x_2	x_1	x_0
---	---	---	-------	-------	-------	-------	-------	-------	-------	-------	-------

168 – 679

- poslední prefix není 1110 ale pouze 111. Použitím 1110 bychom plýtvali neboť z parametrů víme, že se používají právě čtyři skupiny $(9-3)/2 + 1 = 4$

- rozsah hodnot: $0 \leq n < \frac{2^{stop+step} - 2^{start}}{2^{step} - 1} = \frac{2^{9+2} - 2^3}{2^2 - 1} = \frac{2048 - 8}{3} = 680$

Start-Step-Stop kódování

- Pokud jsou parametry *start* a *stop* blízké hodnoty, pak kódová slova mají pouze několik různých délek.
 - Příklad: Start-Step-Stop kód (10,2,14), kde kódové značky jsou organizovány do 3 skupin


n	n th codeword	Number of codewords	Range of integers
0	$0 \underbrace{x \dots x}_{10}$	$2^{10} = 1K$	0–1023
1	$10 \underbrace{xx \dots x}_{12}$	$2^{12} = 4K$	1024–5119
2	$11 \underbrace{xx \dots xx}_{14}$	$2^{14} = 16K$	5120–21503
Total 14		21504	

Start-Step-Stop kódování


- Změnou parametrů lze definovat kódování pro libovolné $n \in \mathbb{N}$ mající různé parametry co se optimality týče
 - exponenciální distribuce hodnot (unární kód), geometrická distribuce hodnot (Golombův kód), ...
- Speciální případy:
 - Trojice $(n, 1, n)$ definuje standardní n -bitové binární kódy, což můžeme ověřit přímou konstrukcí. Snadno zjistíme, že počet těchto kódů je 2^n
 - Trojice $(0, 0, \infty)$ definuje kód 0, 10, 110, 1110, ... , což je unární kód přiřazený celým číslům $\mathbb{N}_0$
 - Trojice $(0, 1, \infty)$ definuje variantu Eliasova gama kódu
 - Trojice (k, k, ∞) definuje další variantu Eliasova gama kódu
 - Trojice $(k, 0, \infty)$ definuje Riceův kód s parametrem k
 - Trojice $(k, 1, \infty)$ definuje exponenciální Golombův kód s parametrem k

Golomb-Riceovy kódy

- Golombův kód (1966) umožňuje zakódovat libovolnou nezápornou hodnotu $n > 0$
 - Kódovou značku pro celé číslo n tvoří dvě části – předpona q a přípona r
 - Hodnoty jsou rozděleny do skupin fixní délky $m \geq 1$ odpovídající parametru kódu, tzv. modulu m
 - Délka kódových slov se postupně prodlužuje s rostoucím indexem skupiny



- Kódové slovo je pro dané m a n tvořeno zřetězením:
 - unárně kódované hodnoty $q = \left\lfloor \frac{n}{m} \right\rfloor$ (celá část po dělení modulem)
 - hodnoty $r = n - qm$ (zbytek po celočíselném dělení modulem) kódované pomocí *zkráceného binárního kódování* (truncated binary encoding)




Golomb-Riceovy kódy

- Hodnota r je kódovaná binárním kódem délky c nebo $c + 1$ bitů
 - Pokud $m \neq 2^c$, pak prvních $2^c - m$ hodnot r je zakódováno jako celá čísla bez znaménka se šířkou $c - 1$ bitů (tj. $\lfloor \log_2 m \rfloor$), zbytek (tj. hodnoty až po $m - 1$) je zakódován se šířkou c bitů (tj. $\lfloor \log_2 m \rfloor + 1$) s tím, že kódujeme hodnotu $r + 2^c - m$
 - Pokud $m = 2^c$, pak se všechny hodnoty r kódují c -bitovými kódy.
- Příklad: Zkonstruuje Golombův kód pro $m = 5$
 - $\lfloor \log_2 5 \rfloor = 2$, $\lceil \log_2 5 \rceil = 3$, $c = 3$, $2^c - m = 3$
 - pro $r = 0, 1, 2$ se 2-bitové binární reprezentace a pro $r = 3, 4$ se použijí 3-bitové binární reprezentace, tj. 00, 01, 10, 110, 111


$0 \rightarrow \mathbf{000},$	$5 \rightarrow \mathbf{1000},$	$10 \rightarrow \mathbf{11000},$	$15 \rightarrow \mathbf{111000},$
$1 \rightarrow \mathbf{001},$	$6 \rightarrow \mathbf{1001},$	$11 \rightarrow \mathbf{11001},$	...
$2 \rightarrow \mathbf{010},$	$7 \rightarrow \mathbf{1010},$	$12 \rightarrow \mathbf{11010},$	
$3 \rightarrow \mathbf{0110},$	$8 \rightarrow \mathbf{10110},$	$13 \rightarrow \mathbf{110110},$	
$4 \rightarrow \mathbf{0111},$	$9 \rightarrow \mathbf{10111},$	$14 \rightarrow \mathbf{110111},$	

Golomb-Riceovy kódy


- Golombův kód pro případ, kdy $m = 2^k$ se nazývá Riceův kód řádu k .
- Celé číslo $n \geq 0$ je kódováno jako dvojice báze a offset.
 - Báze $\lfloor n/2^k \rfloor$ je zakódována unárním kódem zakončeným nulovým bitem a
 - offset odpovídá k nejméně významným bitům binární reprezentace n .
- Příklad:
 - uvažme $k = 2$, tj. $m = 2^2 = 4$ pak hodnota $n = 9$ je zakódována jako 110 01 neboť $\lfloor 9/4 \rfloor = 2$, hodnota $n = 3$ je zakódována jako 0 11 neboť $\lfloor 3/4 \rfloor = 0$
 - Binární stromy reprezentující Riceovo kódování řádu 0, 1 a 2 a Golombovo kódování pro $m=3$:




$m = 2^0$



$m = 2^1$



$m = 3$



$m = 2^2$

Optimalita a význam Golomb-Riceova kódování

- Věta: pro libovolný zdroj dat produkujícího symboly s geometrickým rozdělením

$$P(n) = p^n (1 - p)$$

Ize stanovit m tak, aby Golombovo kódování bylo pro daný zdroj optimální.

- Golombův kód je optimální prefixový kód pro zdroj produkující symboly s geometrickým pravděpodobnostním rozdělením, pokud je m zvoleno tak, že platí

$$m \geq -\frac{\log_2(1+p)}{\log_2 p} > m-1$$

- Pro dané p existuje jediné řešení a sice

$$m = \left\lceil -\frac{\log_2(1+p)}{\log_2 p} \right\rceil$$


- Je-li m dostatečně velké, pak platí $p^m \approx \frac{1}{2}$.

- Využití: Golombův kód se používá pro bezztrátovou kompresi obrazů (bezeztrátový JPEG-LS) a zvukových záznamů (FLAC, Apple Lossless – ALAC, MPEG-4 ALS).

- takové rozdělení produkuje buď binární RLE nebo kódovaná chyba predikce

Význam Golomb-Riceova kódování v oblasti komprese

- Máme-li binární zdroj produkující 0 a 1 nezávisle s pravděpodobností výskytu nuly p , pak pravděpodobnost výskytu sekvence 0^n1 odpovídá $P(n) = p^n (1 - p)$
 - Příklad sekvence: 000001000000001000011100000011
 - Dlouhé sekvence nul implikují $p \approx 1$, tudíž $H(p) = p \log p \ll 1$
 - Entropické kódování aplikované přímo na binární sekvenci bude dosahovat špatných výsledků.
- Použijeme-li RLE kódování na sekvenci nul a jedniček, kdy sekvence 0^n1 je nahrazena hodnotou n (počet nul mezi dvěma jedničkami), pak získáme sekvenci, která vykazuje charakter geometrického rozdělení
 - Pro příklad dostáváme sekvenci r : 5 8 4 0 0 5 0
 - Pro pravděpod. rozdělení RLE sekvence r , platí že $P(r = n) = p^n (1 - p)$, což odpovídá pravděpodobnosti, že n nul je následováno jedničkou



Golomb-Riceovy kódy – využití pro kompresi binárních řetězců

■ Komprese binárního řetězce probíhá následovně:

1. spočítáme počet nul a jedniček,
2. vypočteme pravděpodobnost nuly p ,
3. použijeme rovnici pro výpočet m ,
4. zkonstruujeme třídu Golombových kódů pro m a
5. pro každý sled n nul zapíšeme Golombův kód n do komprimovaného toku.

■ Pokud p nelze stanovit předem, pak je nejlepší volbou adaptivní Golombův kód

- Princip: pro doposud přijatá data vypočítej m tak, aby $p^m \leq \frac{1}{2}$
- Příklad: algoritmus RLGR - *Adaptive Run-Length/Golomb-Rice encoding* použitý v Microsoft RDP RemoteFX, JPEG-LS

■ Vliv parametru m

- Pro malé hodnoty m Golombovy kódy začínají jako krátké a rychle rostou. To je vhodné pro RLE v případech, kdy je pravděpodobnost p nízká, což implikuje velmi málo dlouhých sledů.
- Pro velké hodnoty m jsou počáteční kódy dlouhé, ale jejich délky se zvyšují pomalu. Takové kódy mají smysl pro RLE, kde p je velká, což implikuje, že se dají očekávat dlouhé sledy.

Golomb-Riceovy kódy – odvození kompresního poměru

- Nechť $\mathbb{P}[r = n]$ odpovídá pravd. že hodnota je součástí sledu délky n ($n - 1$ nul následovaných jednou jedničkou). Nechť $m = 2^b$

$$\begin{aligned}
 \mathbb{E}[\text{compression ratio}] \mathbb{P}[r=n] &= \sum_{n=1}^{\infty} (\text{compression ratio of } n\text{-run}) \mathbb{P}[r = n] \\
 &= \sum_{n=1}^{\infty} \frac{b + 1 + \lfloor 2^{-b}(n - 1) \rfloor}{n} \cdot np^{n-1}(1 - p)^2 \\
 &= (1 - p)^2 \sum_{j=0}^{\infty} (b + 1 + j) \cdot \sum_{i=j2^b+1}^{(j+1)2^b} p^{i-1} \\
 &= (1 - p)^2 \sum_{j=0}^{\infty} (b + 1 + j) \cdot (p^{2^b j} - p^{2^b(j+1)}) \\
 &= (1 - p) \cdot \left(b + \sum_{m=0}^{\infty} p^{2^b m} \right) = (1 - p) \cdot \left(b + (1 - p^{2^b})^{-1} \right)
 \end{aligned}$$

- Pro $b = 6$ a $p = 0.99$ dosahuje kompresní účinnosti 91.89% (limit dle Shannonovy věty je 91.92%)

Golomb-Riceovy kódy – příklad komprese délek sledů

- Př. 1: Uvažujme binární řetězec (41 nul, 18 jedniček):
 00000100110001010000001110100010000010001001000110100001001.
- Řetězec má 18 sledů (nuly končící 1) s délkami 5, 2, 0, 3, 1, 6, 0, 0, 1, 3, 5, 3, 2, 3, 0, 1, 4, 2. Jejich střední hodnota je 2.28.
- Pravděpodobnost nuly je $41/(41 + 18) \approx 0.7$, což dá $m = \lceil -\log 1.7 / \log 0.7 \rceil = \lceil 1.487 \rceil = 2$
 $0.7^2 = 0.49$
- Sekvence sledů kódovaná Golombovými kódy pro $m = 2$ jako řetězec 18 kódů:
 1101|100|00|101|01|11100|00|00|01|101|1101|101|100|101|00|01|1100|100
- Výsledkem je 52-bitový řetězec, který komprimuje původních 59 bitů.
- Komprese je velmi malá, protože p není velké. Řetězec má dokonce čtyři sledy délky 0.

$m=2$

0: 00

1: 01

2: 100

3: 101

4: 1100

5: 1101

Golomb-Riceovy kódy – příklad komprese délek sledů

■ Př. 2: Mějme nyní 94-bitový řetězec

00000000001000000000100000001000000000010000000010000000000100000000
1000000010000000000010000000:

- Je tvořen 85 nulami a 9 jedničkami, takže $p = 85/(85 + 9) = 0.9$. Nejlepší hodnota m je proto $m = \lceil -\log 1.9 / \log 0.9 \rceil = \lceil 6.09 \rceil = 7$. Deset sledů nul má délky 10, 9, 7, 11, 8, 12, 8, 7, 10, 7.
- Po zakódování Golombovými kódy pro $m = 7$ dostaneme 47-bitový řetězec
10100|10011|1000|10101|10010|10110|10010|1000|10100|1000
- Kompresní faktor je $94/47 = 2$.

■ Př. 3: Pro řídký binární řetězec tvořený např. 10^6 nulovými bity, a pouze 100 jedničkami.

- Pravděpodobnost nuly je $p = 10^6 / (10^6 + 10^2) = 0.9999$, a odtud $m = 6932$. Předpokládejme zde 101 sledů, každý asi 10^4 nul dlouhý. Golombův kód 10^4 pro $m = 6932$ je dlouhý 14 bitů, takže 101 sledů se dá komprimovat do 1414 bitů, což dává kompresní faktor 707.

Variable-length quantity (VLQ)

- Variable-length quantity je univerzální kódování, které používá k reprezentaci celých čísel oktety (osmice bitů).
 - Původně bylo kódování navrženo pro standard MIDI, nyní lze nalézt jako BASE-128 v Google Protocol Buffer, ASN.1, formátu DWARF, případně .NET funkci BinaryReader/BinaryWriter
- Struktura oktetu:
 - Spodních 7 bitů (B_n) je významových, osmý bit (A) určuje, zda-li následuje další VLQ oktet ($A=1$).

7	6	5	4	3	2	1	0
-	2^6	2^5	2^4	2^3	2^2	2^1	2^0
A_0	B_0						

7	6	5	4	3	2	1	0
-	2^{13}	2^{12}	2^{11}	2^{10}	2^9	2^8	2^7
A_1	B_1						

...

- Příklady:
 - hodnota 254 odpovídá 11111110 binárně, 0xFE hexadecimálně, VLQ: 11111110 00000001 (0xFE 0x01)
 - hodnota 257 odpovídá 00000001 00000001, 0x01 0x01, VLQ: 10000001 00000010 (0x81 0x02)
 - hodnota 65534 odpovídá 11111111 11111110, 0xFF 0xFE, VLQ: 11111110 11111111 00000011 (0xFE 0xFF 0x03)

Eliasovo kódování

- Elias navrhl ve své práci (1975) tři typy prefixových kódů označované jako gama, delta a omega. Myšlenkou je opět rozdělit kódovou značku na dvě části:
 - prefix, který kóduje řád hodnoty a
 - sufix, který kóduje hodnotu samotnou.
- Metoda vychází z principu, že pro libovolné kladné číslo n existuje takové celé číslo M , že $2^M \leq n < 2^{M+1}$ a tudíž můžeme n reprezentovat pomocí dvojice (M, R) neboť platí, že $n = 2^M + R$.
 - Binárně kódovaná hodnota R je maximálně M bitů dlouhá.
- Jednotlivá Eliasova kódování se liší způsobem, jakým se určí a kóduje počet bitů M .
- Jednotlivé varianty Elias definoval pomocí alfa a beta kódování tak, že
 - $\alpha(n)$ odpovídá unárnímu kódu hodnoty n (varianta pro $n \geq 0$, se symbolem 1 jako oddělovačem) a
 - $\beta(n)$ odpovídá binární reprezentaci n počínaje nejlevějším jedničkovým bitem a nejméně významovým bitem konče, tj. $\beta(3) = 11$, $\beta(11) = 1011$, $\beta(32) = 100000$

Eliasovo gama kódování

- Eliasovo gama kódování $\gamma(n)$ pro kladná celá čísla n je definováno takto:
- Nejprve se určí M , jehož hodnota odpovídá délce binární reprezentace $\beta(n)$
 - Příklad: pokud $n = 13$, pak $M = 3$ neboť hodnotu 13 lze reprezentovat na čtyřech bitech jako 1101
- Kódovou značku pak tvoří M nul (tj. unární kód bez oddělovače) následovaných $\beta(n)$ nebo také $\alpha(M)$ následované $\beta(R)$ (tj. M bity $\beta(n)$)
 - Příklad: hodnota $13=2^3+5$ se zakóduje jako 0001101
- Hodnotu M lze uložit na $1 + \lfloor \log_2 n \rfloor$ bitech a tudíž délka kódové značky je $L(n) = 2M - 1 = 2\lfloor \log_2 n \rfloor + 1$
- Gama kód je optimální pro případy, kdy pravděpodobnost výskytu hodnoty n je $P(n) = 2^{-2\lfloor \log_2 n \rfloor - 1} \approx 1/n^2$.

$$1 = 2^0 + 0 = 1$$

$$2 = 2^1 + 0 = 010$$

$$3 = 2^1 + 1 = 011$$

$$4 = 2^2 + 0 = 00100$$

$$5 = 2^2 + 1 = 00101$$

$$6 = 2^2 + 2 = 00110$$

$$7 = 2^2 + 3 = 00111$$

$$8 = 2^3 + 0 = 0001000$$

$$9 = 2^3 + 1 = 0001001$$

$$10 = 2^3 + 2 = 0001010$$

$$11 = 2^3 + 3 = 0001011$$

$$12 = 2^3 + 4 = 0001100$$

$$13 = 2^3 + 5 = 0001101$$

$$14 = 2^3 + 6 = 0001110$$

$$15 = 2^3 + 7 = 0001111$$

Eliasovo delta kódování

$$n = 2^M + R$$

- Kódovou značku Eliasova delta kódování $\delta(n)$ pro kladné celé číslo n tvoří $\gamma(M + 1)$ následované M bity $\beta(R)$.
 - Příklad: $5 = 2^2 + 1 \Rightarrow M=2, R=1 \Rightarrow \gamma(2 + 1) = 011 \beta(1) = 01$
- Délka kódové značka je $L(n) = 2\lfloor \log_2 \log_2 2n \rfloor + \lfloor \log_2 n \rfloor + 1$
- Delta kódování je optimální pro případy, kdy $P(n) = \frac{1}{2n(\log_2 2n)^2}$

$$1 = 2^0 + 0 \rightarrow |M| = 0 \rightarrow 1$$

$$2 = 2^1 + 0 \rightarrow |M| = 1 \rightarrow 0100$$

$$3 = 2^1 + 1 \rightarrow |M| = 1 \rightarrow 0101$$

$$4 = 2^2 + 0 \rightarrow |M| = 2 \rightarrow 01100$$

$$5 = 2^2 + 1 \rightarrow |M| = 2 \rightarrow 01101$$

$$6 = 2^2 + 2 \rightarrow |M| = 2 \rightarrow 01110$$

$$7 = 2^2 + 3 \rightarrow |M| = 2 \rightarrow 01111$$

$$8 = 2^3 + 0 \rightarrow |M| = 3 \rightarrow 00100000$$

$$9 = 2^3 + 1 \rightarrow |M| = 3 \rightarrow 00100001$$

Eliasovo omega kódování

- Konstrukce omega kódu je definována rekurzivně
- Kódování (tvorba kódové značky odzadu):
 1. připoj zezadu bit 0; pokud $n = 1$, kódování ukonči, jinak inicializuj $k = n$
 2. pokud $k \geq 2$, připoj zleva binární reprezentaci $\beta(k)$, aktualizuj k tak, aby odpovídalo počtu přidáných bitů zmenšenému o 1, tj. $k = |\beta(k)| - 1$ a opakuj krok č. 2
- Dekódování:
 - Dekodér inicializuje $n = 1$, načte bit a pokud je 1, načte n dalších bitů a n nastaví na načtenou hodnotu
- Příklad:
 - Číslo 17 je zakódováno jako 0, kterou předchází 5-bitová binární hodnota 10001, před tuto hodnotu je přidána 3-bitová hodnota $5-1=4$ reprezentovaná pomocí 100, před kterou je 2-bitová hodnota čísla $3-1=2$ (10). Takže výsledek je 10|100|10001|0.

1 0
 2 10 0
 3 11 0
 4 10 100 0
 5 10 101 0

6 10 110 0
 7 10 111 0
 8 11 1000 0
 9 11 1001 0
 10 11 1010 0

11 11 1011 0
 12 11 1100 0
 13 11 1101 0
 14 11 1110 0
 15 11 1111 0

16 10 100 10000 0
 17 10 100 10001 0
 18 10 100 10010 0


Eliasovo kódování – kódová slova a jejich délky pro různé varianty

n	$\alpha(n)$	$\gamma(n)$	$\delta(n)$	$\Omega(n)$	$ \alpha(n) $	$ \gamma(n) $	$ \delta(n) $	$ \Omega(n) $
1	1	1	1	0	1	1	1	1
2	01	010	0100	100	2	3	4	3
3	001	011	0101	110	3	3	4	3
4	0001	00100	01100	101000	4	5	5	6
5	00001	00101	01101	101010	5	5	5	6
6	000001	00110	01110	101100	6	5	5	6
7	0000001	00111	01111	101110	7	5	5	6
8	00000001	0001000	00100000	1110000	8	7	8	7
9	000000001	0001001	00100001	1110010	9	7	8	7
10	0000000001	0001010	00100010	1110100	10	7	8	7
100	000000...0001	0000001100100	00111100100	1011011001000	100	13	11	13
1000	000000...0001	00000000001111101000	0001010111101000	11100111111010000	1000	19	16	17
10000	000000...0001	00000000000000010011100010000	00011100011100010000	111101100111000100000	10000	27	20	21
100000	000000...0001	000000000000000000011000011010 100000	00001000110000110101 00000	101001000011000011010 1000000	100000	33	25	28

Exponenciální Golombovy kódy

- Exponenciální Golombovy (Teuhola, 1978) kódy produkují kratší kódová slova oproti Golombovu kódování, mimo to se jedná o **univerzální kódování**.
 - Kódovou značku pro celé číslo n tvoří dvě části – předpona (unární kód) a přípona (kód pevné délky)
 - Hodnoty jsou rozděleny do skupin, jejichž počet prvků exponenciálně roste (u Golombova kódu je fixní)
 - Počáteční velikost skupiny a počet bitů přípony určuje parametr k , přičemž počet prvků odpovídá 2^k


■ Příklad pro $k = 0$




n	$k=0$
0	1
1	010
2	011
3	00100
4	00101
5	00110
6	00111
7	0001000
8	0001001
9	0001010

Exponenciální Golombovy kódy


- Exponenciální Golombův kód pro nezáporná celá čísla n řádu $k = 0$ odpovídá Eliasovu gama kódování hodnoty $\gamma(n + 1)$.
- Exponenciální Golombův kód pro nezáporná celá čísla n řádu $k \geq 1$ definuje kódové slovo pomocí zřetězení:
 - hodnoty $q = \left\lfloor \frac{n}{2^k} \right\rfloor$ (celá část po dělení 2^k , index skupiny) pomocí exponenciálního Golombova kódu řádu nula
 - binárně reprezentované hodnoty $r = n - q2^k$ (zbytek po celočíselném dělení 2^k , index v rámci skupiny)



$k = 0$



$k = 1$




$k = 2$

Exponenciální Golombovy kódy

- Exp. Golombovo kódování řádu $k = 0$ je použito ve standardu H.264/MPEG-4 AVC a H.265 ke kódování celých čísel, neboť
 - (i) dovoluje kompresi – méně často se vyskytujícím hodnotám jsou přiřazena delší kódová slova (vyšší hodnota = delší slovo)
 - (ii) kódování a dekódování lze snadno realizovat v HW
 - (iii) umožňuje mapovat oboustranné distribuce
- Mapování v H264
 - **ue** - Unsigned direct mapping, kladná čísla $x \geq 0$ jsou přímo mapována na hodnotu x (použito pro typ makrobloku, odkaz na index snímku, ...)
 - **se** – Signed mapping, kladná čísla $x > 0$ jsou mapována na liché hodnoty $2x - 1$, zatímco záporné čísla $x \leq 0$ jsou mapována na sudé hodnoty $-2x$ (motion vector difference, delta QP, ...)
 - **te** – Truncated mapping, pokud největší hodnota x je 1, pak se pošle jeden bit ($\bar{x}$), jinak se použije ue
 - **me** - Mapped symbols, číslo je mapováno podle jedné ze čtyř převodních tabulek

Bit pattern	Unsigned (ue)	Signed (se)
1	0	0
010	1	1
011	2	-1
00100	3	2
00101	4	-2
00110	5	3
00111	6	-3
0001000	7	4
0001001	8	-4
0001010	9	5
0001011	10	-5



Vlastnosti kódování celých čísel

- Kódování jsou optimální pro následující rozložení pravděpodobnosti

Kódování	Pravděpodobnost výskytu hodnoty n
Unární	$P(n) = 2^{-n}$
Golombovo, parametr m	$P(n) = p^n (1 - p) \approx \frac{2}{m} 2^{\lfloor \frac{n}{m} \rfloor} \approx (\sqrt[m]{2})^{-n}$
Eliasovo gama (Golombovo exp. $k = 0$)	$P(n) = 2^{-2\lfloor \log_2 n \rfloor + 1} \approx 1/n^2$
Eliasovo delta	$P(n) = \frac{1}{2n(\log_2 2n)^2}$
Eliasovo omega	$P(n) \approx \frac{1}{n \log_2(n) \log_2(\log_2(n)) \dots}$

- Pokud použijeme kódování optimální pro q_i na jinou distribuci (p_i), bude dle Kullback-Leiblerovy divergence nutné použít více bitů na symbol (vzniká redundance)

$$\Delta H = \sum_i p_i \lg(1/q_i) - \sum_i p_i \lg(1/p_i) = \sum_i p_i \lg\left(\frac{p_i}{q_i}\right) \approx \frac{1}{\ln(4)} \sum_i \frac{(p_i - q_i)^2}{p_i}$$

Očekávané znalosti

■ Teorie

- Definovat kódování, popsat prefixové kódování, jednoznačně dekódovatelné kódování, umět poznat vlastnosti daného kódování (aplikace Kraft-McMillanovy nerovnosti), porozumět vztahu mezi entropií a délkou kódových značek, tvorba stromu pro daný kód
- Umět spočítat entropii prvního řádu, entropii Markovského řetězce prvního řádu

■ Kódy

- Umět zkonstruovat unární kód, Eliasův gama a delta kód, Golombův kód (není třeba znát vztah pro výpočet optimálního parametru)
- Rozlišit, kdy je výhodné použít které kódování
- Umět aplikovat Eliasův gama kód na MTF a Golombovo kódování na kompresi RLE výstupu